



17º Congresso de Inovação, Ciência e Tecnologia do IFSP - 2026 Campus Guarulhos

FALAI DOUTOR: SISTEMA DE APOIO À PRÉ-TRIAGEM HOSPITALAR COM INTELIGÊNCIA ARTIFICIAL GENERATIVA

Área de conhecimento (Tabela CNPq): 1.03.03.04-9 Sistemas de Informação.

RESUMO: Este trabalho apresenta o FalAI Doutor, um sistema de apoio à pré-triagem hospitalar que emprega inteligência artificial generativa para organizar relatos de sintomas e sugerir uma classificação preliminar de risco. O Protocolo de Manchester é adotado como referência do produto, enquanto o Emergency Severity Index (ESI) é utilizado como apoio metodológico para avaliação dos modelos. A solução foi projetada com interface web, serviços de aplicação, persistência relacional e integração com modelos de linguagem. Para verificar a viabilidade da abordagem, três modelos foram avaliados em 100 casos de triagem distribuídos igualmente entre os cinco níveis do ESI. O Llama 3.3 70B obteve a maior acurácia global (64%), seguido pelo Qwen3 32B (54%) e pelo GPT-OSS 120B (50%). Os modelos apresentaram melhor desempenho nos níveis ESI-2 e ESI-3 e maior dificuldade no ESI-1, correspondente aos casos mais críticos. Os resultados indicam potencial para apoio à coleta e organização inicial das informações, mas reforçam que a classificação definitiva deve permanecer sob responsabilidade de profissionais de saúde.

PALAVRAS-CHAVE: classificação de risco; modelos de linguagem; emergência; saúde digital; pré-triagem.

FALAI DOUTOR: GENERATIVE ARTIFICIAL INTELLIGENCE SUPPORT SYSTEM FOR HOSPITAL PRE-TRIAGE

ABSTRACT: This work presents FalAI Doutor, a hospital pre-triage support system that uses generative artificial intelligence to organize symptom reports and suggest a preliminary risk classification. The Manchester Triage System is adopted as the product reference, while the Emergency Severity Index (ESI) is used as a methodological support for model evaluation. The solution was designed with a web interface, application services, relational data persistence, and integration with large language models. To assess the feasibility of the approach, three models were evaluated on 100 triage cases equally distributed across the five ESI levels. Llama 3.3 70B achieved the highest overall accuracy (64%), followed by Qwen3 32B (54%) and GPT-OSS 120B (50%). The models performed better on ESI-2 and ESI-3 and showed greater difficulty on ESI-1, which represents the most critical cases. The results indicate potential for supporting the initial collection and organization of clinical information, but reinforce that the final risk classification must remain under the responsibility of healthcare professionals.

KEYWORDS: risk classification; language models; emergency care; digital health; pre-triage.

INTRODUÇÃO

A triagem hospitalar organiza o atendimento de urgência segundo a gravidade clínica, e não apenas pela ordem de chegada. Sistemas estruturados de classificação de risco buscam aumentar a consistência desse processo e reduzir atrasos em casos críticos. Entre eles, o Protocolo de Manchester utiliza fluxogramas e discriminadores clínicos para relacionar sinais e sintomas a categorias de prioridade e tempos máximos recomendados de espera (SILVA et al., 2021). O Emergency Severity Index (ESI), por sua vez, também estratifica pacientes por gravidade e necessidade de recursos e possui estudos de aplicação no contexto brasileiro (HINSON et al., 2018).

Modelos de linguagem de grande porte (LLMs), derivados de avanços na arquitetura Transformer (VASWANI et al., 2017), ampliaram a capacidade de interpretar relatos em linguagem natural. Na emergência, essa característica pode ser útil para transformar descrições livres em informações estruturadas e apoiar a organização inicial dos casos. Entretanto, evidências recentes apontam simultaneamente potencial para apoio a decisões e limitações de segurança quando esses modelos são empregados de forma autônoma, sobretudo em casos graves (SHEN et al., 2026; SARBAY et al., 2026).

Nesse contexto, o FalAI Doutor propõe uma camada de apoio à pré-triagem: o paciente relata seus sintomas por interface web ou estação de autoatendimento, a aplicação organiza as informações e um LLM sugere uma prioridade preliminar acompanhada de justificativa. A decisão assistencial permanece com o profissional responsável, em consonância com a lógica de acolhimento e classificação de risco adotada nos serviços de urgência (Brasil. Ministério da Saúde. Secretaria de Atenção à Saúde, 2009). O objetivo deste trabalho é descrever a solução desenvolvida e avaliar, de forma inicial, o desempenho de diferentes LLMs na classificação de casos segundo o ESI, identificando oportunidades e limitações para sua utilização como ferramenta de apoio.

MATERIAIS E MÉTODOS

O desenvolvimento foi conduzido como um projeto aplicado de software para apoio à pré-triagem. A arquitetura foi organizada em camadas desacopladas: interface em Angular para coleta e visualização das informações; serviços de aplicação para validação e orquestração das requisições; PostgreSQL para persistência; e integração com serviços de inferência de IA. A execução dos modelos foi planejada por Ollama ou Groq, permitindo alternar entre processamento local e remoto. A solução também prevê APIs para integração futura com sistemas hospitalares. Essa separação favorece manutenção, escalabilidade e implantação gradual (BASS; CLEMENTS; KAZMAN, 2012).

O fluxo proposto inicia com o relato textual dos sintomas. As informações são convertidas para uma representação estruturada, preservando o texto original para auditoria. O modelo recebe instruções para não realizar diagnóstico, apresentar uma classificação preliminar e justificar os sinais considerados relevantes. No produto, o Manchester é a referência de organização clínica; na etapa experimental, utilizou-se o ESI por sua disponibilidade de casos estruturados e pela possibilidade de comparação objetiva entre a classe esperada e a classe sugerida.

Para a avaliação inicial foi utilizado o conjunto *mimiciv-triage-eval-dataset-v1*, com 100 casos, sendo 20 para cada nível ESI. Foram testados GPT-OSS 120B, Qwen3 32B e Llama 3.3 70B sob o mesmo formato de tarefa. Para cada caso, registrou-se se a classificação prevista correspondia ao nível esperado. A métrica principal foi a taxa de acerto por classe e global. Esta avaliação mede concordância com os rótulos do conjunto utilizado; portanto, não equivale a uma validação clínica prospectiva nem autoriza uso autônomo da solução.

RESULTADOS E DISCUSSÃO

A Tabela 1 apresenta a taxa de acerto dos três modelos por nível ESI. O Llama 3.3 70B obteve o melhor desempenho global, com 64%, seguido por Qwen3 32B, com 54%, e GPT-OSS 120B, com 50%.

Tabela 1: Taxa de acerto dos modelos por nível ESI.

Nível	GPT-OSS 120B	Qwen3 32B	Llama 3.3 70B
ESI-1	10%	50%	20%
ESI-2	70%	80%	95%
ESI-3	70%	75%	90%
ESI-4	50%	35%	45%
ESI-5	50%	30%	70%
Global	50%	54%	64%

O desempenho foi mais consistente nos níveis ESI-2 e ESI-3. O Llama 3.3 70B atingiu 95% e 90%, respectivamente, e o Qwen3 32B alcançou 80% e 75%. Em contrapartida, o ESI-1 apresentou os resultados mais preocupantes: 10% para GPT-OSS 120B, 50% para Qwen3 32B e 20% para Llama 3.3 70B. Como o ESI-1 representa situações de maior gravidade, erros nessa categoria possuem impacto potencialmente maior que erros em níveis menos urgentes. Assim, a acurácia global, isoladamente, não é suficiente para determinar segurança de uso.

Outro resultado relevante é que o modelo com maior número de parâmetros não apresentou o melhor desempenho. O GPT-OSS 120B ficou abaixo do Qwen3 32B e do Llama 3.3 70B, indicando que tamanho do modelo não determina sozinho a qualidade da classificação. Arquitetura, dados de treinamento, alinhamento às instruções e adequação do *prompt* à tarefa também influenciam a resposta. Para o projeto, esse achado é importante porque modelos menores podem reduzir custo e exigência de infraestrutura, desde que atinjam desempenho adequado em métricas clinicamente relevantes.

Os resultados são compatíveis com a literatura que trata os LLMs como tecnologias promissoras para apoio, mas ainda insuficientes para substituir a avaliação profissional (SHEN et al., 2026; SARBAY et al., 2026). No FalAI Doutor, essa limitação orientou uma decisão de projeto: a IA deve organizar o relato, destacar sinais relevantes, sugerir uma prioridade e registrar sua justificativa, enquanto a confirmação ou alteração da classificação permanece com a equipe de saúde. Essa abordagem também favorece rastreabilidade e permite comparar posteriormente a sugestão automática com a decisão profissional.

Além da etapa experimental, foi desenvolvido um protótipo com fluxos separados para paciente e equipe de saúde. A área do paciente permite identificação e registro conversacional de sintomas; a área profissional apresenta casos pendentes, dados estruturados, sugestão preliminar de risco e justificativa, com possibilidade de revisão humana. Uma versão da aplicação está disponível para acesso em <<https://frontendfalaidoutor.vercel.app/>>. O protótipo demonstra a viabilidade de integrar a coleta em linguagem natural ao fluxo de atendimento, mas ainda necessita de testes de usabilidade e integração em ambiente hospitalar real.

A comparação com alternativas tradicionais também evidencia o posicionamento da proposta. Sistemas de gestão hospitalar concentram-se no prontuário e na fila; totens convencionais utilizam formulários estáticos; e verificadores de sintomas costumam atuar fora do fluxo presencial. O FalAI Doutor busca combinar autoatendimento, linguagem natural e apoio à equipe no próprio processo de pré-triagem. Seu principal desafio, contudo, não é apenas tecnológico: qualquer implantação exige validação clínica, proteção de dados, integração institucional e definição clara de responsabilidade humana.

CONCLUSÕES

O FalAI Doutor demonstrou viabilidade técnica inicial como ferramenta de apoio à pré-triagem hospitalar. Entre os modelos avaliados, o Llama 3.3 70B apresentou a maior taxa global de acerto (64%), enquanto o Qwen3 32B obteve 54% e o GPT-OSS 120B, 50%. O desempenho elevado em ESI-2 e ESI-3 mostra potencial para auxiliar a organização de casos intermediários, mas a baixa consistência observada no ESI-1 impede qualquer interpretação de que os modelos estejam prontos para classificação clínica autônoma.

Conclui-se, portanto, que o uso mais adequado da IA no escopo atual é como suporte à coleta, estruturação e priorização preliminar das informações, mantendo validação humana obrigatória. Como continuidade, pretende-se ampliar o conjunto de testes, medir subtriagem e supertriagem, comparar as respostas com classificações de profissionais de saúde, avaliar usabilidade do protótipo e estudar mecanismos de recuperação de diretrizes clínicas que possam aumentar a consistência das justificativas sem retirar o profissional do processo decisório.

AGRADECIMENTOS

REFERÊNCIAS

BASS, L.; CLEMENTS, P.; KAZMAN, R. *Software Architecture in Practice*. 3. ed. Boston: Addison-Wesley, 2012. ISBN 9780321815736.

Brasil. Ministério da Saúde. Secretaria de Atenção à Saúde. *Acolhimento e classificação de risco nos serviços de urgência*: Política nacional de humanização da atenção e gestão do sus. Brasília, DF: Ministério da Saúde, 2009. 56 p. (Série B. Textos Básicos de Saúde). Disponível em: <https://bvsms.saude.gov.br/bvs/publicacoes/acolhimento/_classificacao/_risco/_servico/_urgencia.pdf>. Acesso em: 10 ago. 2026.

HINSON, J. S. et al. Accuracy of emergency department triage using the emergency severity index and independent predictors of under-triage and over-triage in brazil: a retrospective cohort analysis. *International Journal of Emergency Medicine*, v. 11, p. 3, 2018. DOI: 10.1186/s12245-017-0161-8. Disponível em: <<https://doi.org/10.1186/s12245-017-0161-8>>. Acesso em: 10 ago. 2026.

SARBAY, I. et al. Trauma triage performance of large language models on raw turkish emergency notes: artificial intelligence versus human expertise. *Hong Kong Journal of Emergency Medicine*, v. 33, n. 1, 2026. DOI: 10.1002/hkj2.70083. Disponível em: <<https://doi.org/10.1002/hkj2.70083>>. Acesso em: 10 ago. 2026.

SHEN, Z. et al. Enhancing emergency medical service diversion decision-making through large language models integration. *Intelligent Medicine*, v. 6, n. 1, p. 56–68, 2026. DOI: 10.1016/j.imed.2025.04.004. Disponível em: <<https://doi.org/10.1016/j.imed.2025.04.004>>. Acesso em: 10 ago. 2026.

SILVA, L. R. e. et al. Protocolo de manchester: implementação e execução. *Revista Gestão & Tecnologia*, Goiânia, v. 1, n. 32, p. 33–44, 2021. Disponível em: <<https://www.faculdedelta.edu.br/revistas3/index.php/gt/article/view/70/55>>. Acesso em: 10 ago. 2026.

VASWANI, A. et al. Attention is all you need. *Advances in Neural Information Processing Systems*, v. 30, p. 5998–6008, 2017. Disponível em: <<https://proceedings.neurips.cc/paper/7181-attention-is-all-you-need>>. Acesso em: 10 ago. 2026.